UNIVERSIDAD TECNOLÓGICA DE PUEBLA

LICENCIATURA EN INGENIERÍA EN TECNOLOGÍAS DE LA INFORMACIÓN E INNOVACIÓN DIGITAL

Ensayo sobre Ética y aspectos sociales de la Inteligencia Artificial

FUNDAMENTOS DE INTELIGENCIA ARTIFICIAL

DOCENTE: MATHER XOCHITL MENDOZA PISCIL

ALUMNO:
CESAR HESSIEL AREVALO SANCHEZ

MATRÍCULA: UTP0153205

7 C

28 de septiembre de 2026

Índice

01. Introducción: La Gran Encrucijada Sociotécnica **3**

02. I. Sesgos Algorítmicos, Discriminación Sistémica y la Falacia de la Neutralidad **4**

03. II. La Metamorfosis del Trabajo, Automatización y Desigualdad Estructural **5**

04. III. Privacidad, Capitalismo de Vigilancia y la Erosión del Ecosistema Democrático **6**

05. IV. Autonomía, Rendición de Cuentas y el Problema de la 'Caja Negra' **7**

06. V. Hacia una Gobernanza Global y una IA Antropocéntrica: Propuestas y Conclusiones **8**

Referencias bibliográficas **10**

01. Introducción: La Gran Encrucijada Sociotécnica

Del cálculo estadístico a la mediación de la existencia humana

A lo largo de la historia de la civilización, cada salto tecnológico transformador —desde el dominio del fuego y la invención de la imprenta hasta la revolución del vapor y la fisión nuclear— ha obligado a la humanidad a replantearse sus marcos éticos, jurídicos y filosóficos. Sin embargo, la revolución de la Inteligencia Artificial (IA) que presenciamos en la actualidad posee una naturaleza ontológica sin precedentes: ya no estamos ante meros instrumentos mecánicos diseñados para amplificar la fuerza física del ser humano, sino ante sistemas con facultades para procesar información simbólica, formular predicciones inductivas, sintetizar representaciones del mundo y tomar o sugerir decisiones determinantes sobre la vida de miles de millones de personas.

Durante décadas, la ciencia de la computación cultivó una visión positivista y tecnocéntrica en la que los algoritmos eran concebidos como entidades estrictamente racionales, asépticas y desprovistas de las debilidades emocionales y prejuicios inherentes a la mente humana. No obstante, la experiencia empírica de la última década ha derrumbado estrepitosamente dicho mito fundacional. Como señalan sociólogos y tecnólogos críticos, la IA no opera en un vacío matemático ideal: se nutre de datos producidos por sociedades humanas asimétricas, incompletas y conflictivas. En consecuencia, lejos de erradicar los defectos del juicio humano, los modelos de aprendizaje automático tienden a absorberlos, sistematizarlos y amplificarlos a una escala y velocidad antes inimaginables.

Ante este panorama, la ética de la inteligencia artificial ha dejado de ser una disquisición abstracta o un ejercicio secundario de relaciones públicas para convertirse en un imperativo de supervivencia civilizatoria. ¿Quién responde cuando un algoritmo niega una hipoteca a una familia de escasos recursos? ¿Cómo garantizamos la equidad en sistemas de reclutamiento laboral gobernados por redes neuronales opacas? ¿Qué límites morales deben restringir la delegación de la fuerza letal a máquinas de guerra autónomas? Este ensayo propone examinar críticamente las luces y sombras de este paradigma, estructurando la discusión en torno a los desafíos éticos cardinales y delineando propuestas concretas hacia una gobernanza antropocéntrica.

02. I. Sesgos Algorítmicos, Discriminación Sistémica y la Falacia de la Neutralidad

Cuando los datos históricos convierten el pasado en una condena para el futuro

El primer y más palpable dilema social de la IA contemporánea reside en el fenómeno del sesgo algorítmico (algorithmic bias). Para comprender su gravedad, es necesario desmitificar la fuente de la que bebe el aprendizaje automático: los datos históricos de entrenamiento. Un modelo de Machine Learning es, en esencia, un espejo estadístico retrospectivo. Si los datos con los que se entrena reflejan décadas de discriminación racial, segregación socioeconómica, disparidades de género o exclusión territorial, el algoritmo inferirá que dichas disparidades no son contingencias históricas corregibles, sino leyes probabilísticas naturales que deben preservarse y replicarse.

Un caso paradigmático y ampliamente documentado fue el del software COMPAS (Correctional Offender Management Profiling for Alternative Sanctions), utilizado por tribunales de justicia en Estados Unidos para predecir el riesgo de reincidencia delictiva de personas imputadas. La célebre investigación de ProPublica demostró que, al calcular el riesgo, el algoritmo arrojaba casi el doble de falsos positivos en personas afroamericanas que en personas caucásicas, catalogándolas como sujetos de alta peligrosidad aun cuando sus antecedentes delictivos eran sustancialmente menores. El modelo no contenía una variable explícita de 'raza', pero identificaba correlaciones espurias a través de variables sustitutas (proxies) como el código postal, ingresos familiares o vecindario de origen.

Situaciones similares se han repetido en el ámbito corporativo. Cuando gigantes tecnológicos como Amazon desarrollaron herramientas de IA para filtrar currículums vitae con base en las contrataciones de los últimos diez años, el sistema aprendió automáticamente a penalizar cualquier solicitud que incluyera la palabra 'mujeres' o que mencionara instituciones educativas femeninas, debido a que el historial histórico de contratación en ingeniería había estado históricamente masculinizado. Estos ejemplos evidencian que el sesgo no es una falla accidental de programación, sino una propiedad inherente de los sistemas de datos cuando se carece de auditorías de equidad (fairness), representatividad muestral y marcos de diseño ético desde las etapas tempranas del ciclo de vida del software.

03. II. La Metamorfosis del Trabajo, Automatización y Desigualdad Estructural

La disrupción sobre el trabajo intelectual y la concentración desmedida de riqueza

Históricamente, los defensores de la teoría de la compensación económica sostenían que toda ola de destrucción creativa impulsada por la tecnología destruía ciertos oficios obsoletos pero creaba, simultáneamente, un número equivalente o superior de empleos más calificados y mejor remunerados. Sin embargo, la naturaleza de la IA generativa y los agentes inteligentes actuales desafía directamente esta premisa tradicional.

A diferencia de las revoluciones industriales previas, que automatizaron primordialmente tareas físicas, manuales y repetitivas, la frontera de la IA impacta de lleno en el trabajo cognitivo, creativo y analítico: traducción profesional, redacción jurídica, diagnóstico radiológico, atención al cliente, diseño gráfico y redacción de código computacional. Si bien la tecnología potencia la productividad individual de manera extraordinaria, también plantea un riesgo severo de precarización laboral y desplazamiento abrupto de millones de trabajadores cuyas curvas de adaptación profesional no pueden competir con la velocidad de despliegue de los modelos fundacionales.

Este fenómeno amenaza con agudizar la polarización económica global. Por un lado, una élite minúscula compuesta por corporaciones multinacionales que concentran los centros de cómputo, las reservas de datos masivos y los talentos de frontera absorbe rentas económicas casi monopolísticas. Por otro lado, amplias capas de la población activa enfrentan la amenaza de la obsolescencia o la subordinación a economías de plataforma (gig economy) intermediadas por algoritmos que dictan horarios, ritmos y tarifas sin ningún tipo de protección sindical o negociación colectiva. Por ende, la discusión ética no puede desligarse de la justicia distributiva: se vuelve indispensable plantear políticas estructurales como la Renta Básica Universal (UBI), impuestos a la automatización extrema y fondos públicos dedicados a la recalificación profesional continua.

04. III. Privacidad, Capitalismo de Vigilancia y la Erosión del Ecosistema Democrático

La mercantilización de la conducta y la posverdad algorítmica

En su influyente obra 'La era del capitalismo de vigilancia', la profesora Shoshana Zuboff describe con agudeza cómo las grandes plataformas tecnológicas han transformado la experiencia humana íntima en materia prima gratuita destinada a alimentar modelos predictivos de comportamiento. Cada búsqueda, cada clic, cada pausa al deslizar la pantalla, cada mensaje de texto y cada desplazamiento geográfico es rastreado minuciosamente para construir perfiles psicométricos hiperindividualizados, orientados a modificar inadvertidamente las decisiones de consumo y las preferencias ideológicas de los ciudadanos.

La convergencia de estos motores de perfilado con la IA generativa multimodal ha dado origen a una crisis epistemológica de enormes proporciones. La proliferación de deepfakes ultrarrealistas, la clonación de voz en tiempo real y las granjas automatizadas de bots conversacionales permiten orquestar campañas masivas de desinformación personalizada a un costo marginal prácticamente nulo. Como se constató en sucesos como el escándalo de Cambridge Analytica o en recientes procesos electorales alrededor del planeta, los algoritmos optimizados exclusivamente para maximizar el tiempo de retención y la interacción tienden a amplificar el contenido polarizante, sensacionalista y conspirativo, dado que la indignación emocional genera mayor tracción digital que la ponderación racional.

Cuando la verdad compartida y los consensos fácticos básicos se disuelven en cámaras de eco algorítmicas, el propio andamiaje de la deliberación democrática se ve comprometido. La privacidad, lejos de ser un mero derecho individual a estar a solas, emerge entonces como una condición sine qua non para el ejercicio de la autonomía política y la libertad de pensamiento en el siglo XXI.

05. IV. Autonomía, Rendición de Cuentas y el Problema de la 'Caja Negra'

El dilema de la delegación moral y los límites de la máquina

Uno de los obstáculos técnicos con mayores ramificaciones éticas en el aprendizaje profundo es la opacidad explicativa, comúnmente denominada el problema de la 'Caja Negra' (Black Box). En redes neuronales que cuentan con cientos de miles de millones de parámetros y capas ocultas entrelazadas, resulta matemáticamente inviable rastrear con exactitud la cadena de deducciones causales que condujo a una inferencia o recomendación específica. Esto entra en colisión directa con principios jurídicos elementales, tales como el debido proceso y el derecho humano a la explicabilidad: si un ciudadano es encarcelado, despedido o privado de atención médica por la decisión de un sistema algorítmico, ¿cómo puede ejercer su derecho legítimo a la apelación si nadie comprende el mecanismo interno que determinó su destino?

El dilema alcanza su cúspide cuando examinamos la autonomía crítica. En el ámbito civil, los vehículos autónomos enfrentan variantes contemporáneas del clásico dilema del tranvía (trolley problem): en una colisión inminente, ¿cómo debe ponderar el software de control el valor de la vida de sus ocupantes frente a la de un grupo de peatones en la calzada? ¿Es admisible que criterios de optimización numérica decidan dilemas éticos que han dividido a filósofos durante milenios?

Más alarmante aún es la esfera militar con el surgimiento de los Sistemas de Armas Autónomas Letales (LAWS), popularmente conocidos como 'robots asesinos'. La posibilidad de que drones autónomos, equipados con visión por computadora y algoritmos de selección de objetivos, ejerzan la fuerza letal sin intervención humana directa representa una transgresión moral inaceptable. Como han reclamado reiteradamente comités de la ONU y miles de científicos internacionales, la decisión irrevocable de poner fin a una vida humana no puede ni debe ser jamás delegada a un conjunto de operaciones matriciales sin consciencia, empatía, sentido de la piedad ni rendición de cuentas moral.

06. V. Hacia una Gobernanza Global y una IA Antropocéntrica: Propuestas y Conclusiones

Diseñar la tecnología al servicio de la dignidad y la justicia colectiva

Frente a la magnitud de los desafíos descritos, resulta evidente que la autorregulación voluntaria de la industria tecnológica es manifiestamente insuficiente. Las empresas se encuentran sujetas a presiones competitivas feroces que incentivan el lanzamiento prematuro de modelos no testeados rigurosamente. Por consiguiente, se requiere con urgencia una arquitectura integral de gobernanza pública internacional y normativas jurídicas vinculantes.

En este sentido, hitos como la Recomendación sobre la Ética de la Inteligencia Artificial aprobada por los 193 Estados Miembros de la UNESCO en 2021 y, de manera muy destacada, el Reglamento de Inteligencia Artificial de la Unión Europea (EU AI Act) aprobado en 2024 marcan la ruta a seguir. Este último introduce un enfoque pragmático basado en niveles de riesgo: prohíbe taxativamente sistemas inaceptables (como la puntuación social biométrica o la manipulación subliminal), somete a requisitos estrictos de auditoría y transparencia a los sistemas de alto riesgo (empleo, salud, justicia, infraestructura crítica) y garantiza los derechos de los usuarios frente a la IA generativa.

Para hacer realidad una Inteligencia Artificial verdaderamente ética y al servicio del bienestar colectivo, se proponen cinco principios rectores indispensables para desarrolladores, instituciones y tomadores de decisiones:

1. Ética por Diseño (Ethics by Design): Integrar metodologías de evaluación de impacto social y auditorías de mitigación de sesgos desde la formulación matemática inicial, y no como un parche posterior.

2. Transparencia y Explicabilidad (XAI): Prohibir el uso de modelos de caja negra en ámbitos donde estén en juego derechos fundamentales (justicia penal, salud, créditos y educación).

(Continuación)

3. Principio de Control Humano Significativo (Human-in-the-Loop): Asegurar que toda decisión crítica mantenga siempre la supervisión, aprobación y responsabilidad última de un ser humano calificado.

4. Soberanía de Datos y Privacidad por Defecto: Proteger la identidad ciudadana, garantizar el consentimiento informado explícito y frenar el extractivismo de datos no consentido.

5. Democratización y Acceso Equitativo: Evitar que el dividendo tecnológico se concentre en un oligopolio geográfico o corporativo, promoviendo infraestructuras abiertas y bien público digital.

En última instancia, la Inteligencia Artificial no es un destino inexorable que nos cae del cielo como una tormenta climática; es una creación deliberada de nuestra propia inteligencia e inventiva. La IA funciona como un espejo gigante y de altísima fidelidad: lo que refleja no es el futuro de las máquinas, sino la estatura moral y las prioridades éticas de la propia humanidad. Es nuestra responsabilidad histórica colectiva decidir si utilizaremos este poder sin precedentes para profundizar las brechas de la desigualdad o para construir una sociedad más justa, digna, inclusiva y humana.

Referencias bibliográficas

Buolamwini, J., & Gebru, T. (2018). *Gender Shades: Intersectional Accuracy Disparities in Commercial Gender Classification*. Proceedings of Machine Learning Research (PMLR), 81, 77-91.

Floridi, L., & Cowls, J. (2019). *A Unified Framework of Five Principles for AI Ethics*. Harvard Data Science Review, 1(1). https://doi.org/10.1162/99608f92.8cd550d1

O'Neil, Cathy (2016). *Weapons of Math Destruction: How Big Data Increases Inequality and Threatens Democracy*. Crown Publishing Group, New York.

Russell, Stuart (2019). *Human Compatible: Artificial Intelligence and the Problem of Control*. Viking Press, Penguin Random House.

UNESCO (2021). *Recomendación sobre la Ética de la Inteligencia Artificial*. Organización de las Naciones Unidas para la Educación, la Ciencia y la Cultura, París.

Unión Europea (2024). *Reglamento (UE) 2024/1689 del Parlamento Europeo y del Consejo por el que se establecen normas armonizadas en materia de inteligencia artificial (Ley de IA)*. Diario Oficial de la Unión Europea.

Zuboff, Shoshana (2019). *The Age of Surveillance Capitalism: The Fight for a Human Future at the New Frontier of Power*. PublicAffairs, New York.